교수님 보고 2026-10-29

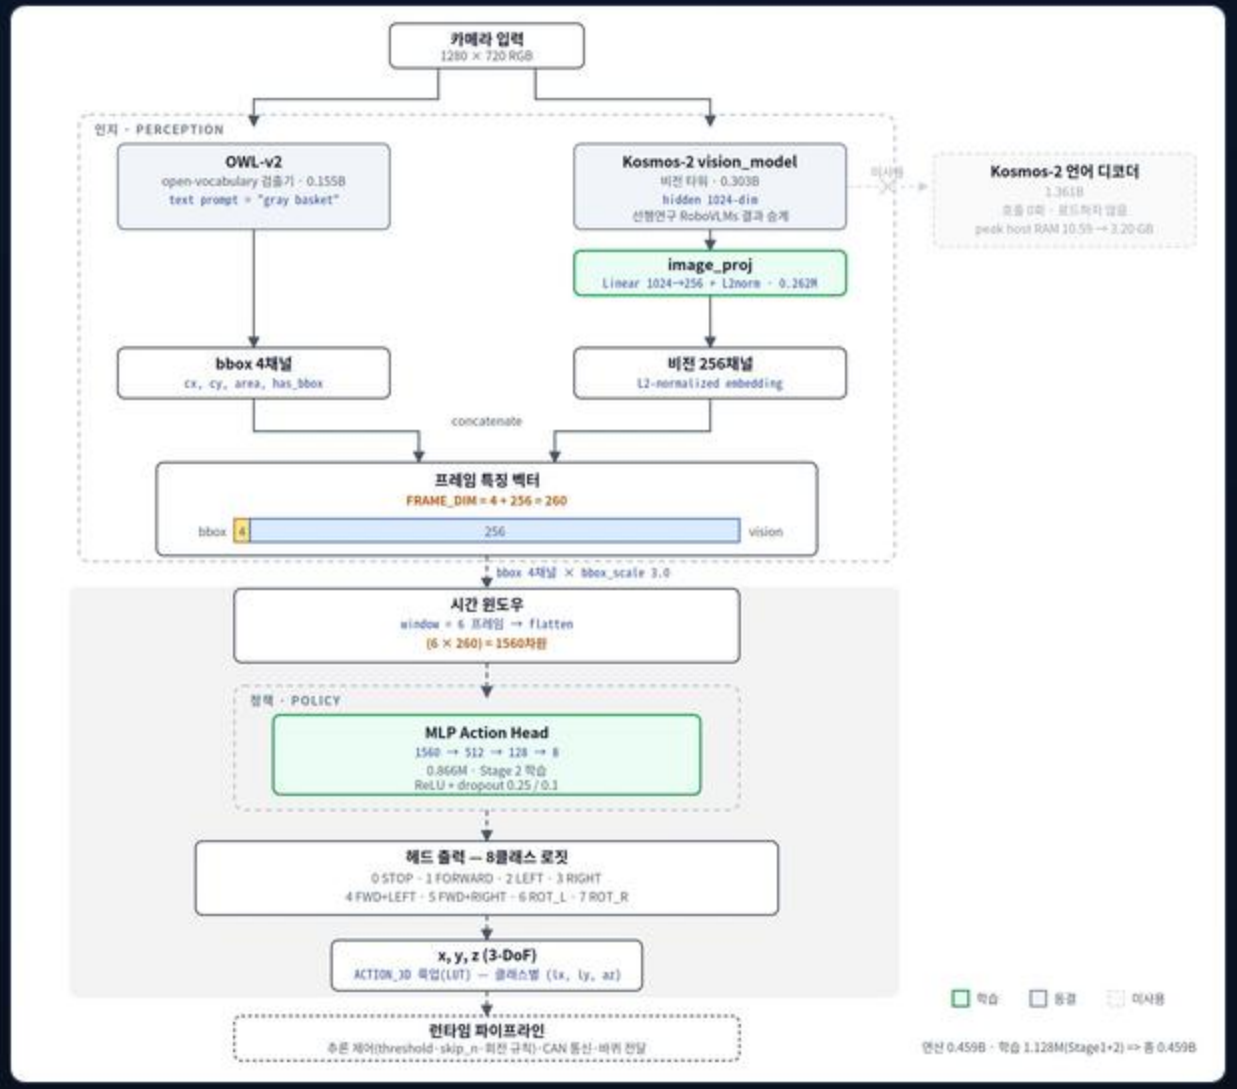
EGVLA2: 단일 백본(Florence-2) 내비게이션 정책 — 실기 폐루프 결과와 현재 모델 확정(A3)

① 무엇을 만들었나 ② 무엇을 시도했나 ③ 실기에서 무엇이 확인됐나 ④ 한계와 다음 단계 ⑤ 참고 문헌

상세: research_story.html#ch79 (📍 현재 상황 탭, 5-2절)

1. 구조 — 두 모델 한눈에

EGVLA1(OWLv2 + Kosmos-2) → EGVLA2(Florence-2 하나로 통합)



EGVLA1: 검출기 + 비전 타워 두 개, MLP 분류 헤드 · 실기 92.0%(276/300)

카메라 이미지

▼

Florence-2 한 번의 인코딩
bbox(cx,cy,area) + 이미지 특징 768-d 동시 추출

▼

bbox 3프레임 창 12-d + 특징 768-d

▼

Flow-matching 행동 헤드 (π0식 AdaLN, H=8)
연속 조이스틱: 방향각 + 속도

▼

서빙: 서보 혼합(선택) → 로봇 명령

· 모델 2개 → **1개**, 헤드는 분류 → **연속 행동**

· 학습: 300 에피소드 · 29,161프레임(pos1)

코드: robovlm_nav/models/egvla2_fm_heads.py · 구조도: docs/v5/figures

2. 시도한 것과 결과 요약

오프라인(같은 분할·라벨·지표) 비교 — 사람 방향 오차(°)는 낮을수록 사람 조작과 같음



E2E(DaViT 미세조정) 변형은 기존 고정 융합 특징(A)을 못 이김. 3분할 평균. 저예산 변형(1 seed, 8 epoch, LoRA 미튜닝)만 시험했으므로 "E2E 무용"이 아니라 "이 변형들은 이득 없음"

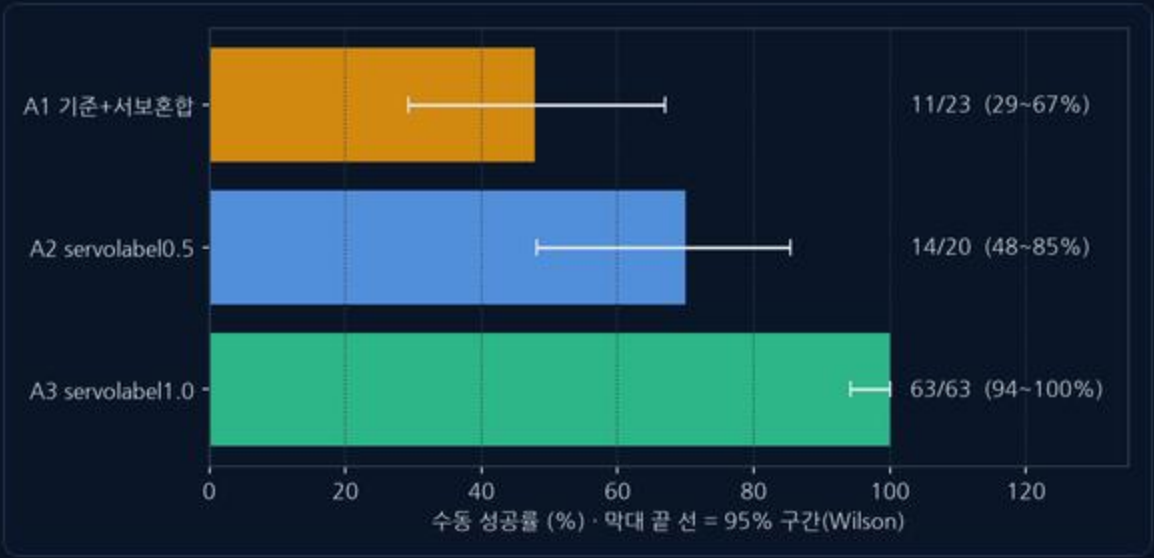
시도	결과
월드모델식 보조 손실 (미래 bbox·특징 변화 예측)	변화 예측은 잘함, **타깃 반응 S는 안 오름** → 1단계에서 중단
서보 라벨(타깃으로 향하는 방향 라벨 혼합)	타깃 반응 S ↑, 오프라인 방향 오차는 ↑(나빠짐)
서버 서보 혼합(A1)	실기 11/23 — 효과 약함

핵심: 오프라인 방향 오차는 모델 선택 기준으로 **부적합**(A3는 +22° 나쁜데 실기는 최고) → 선택은 실기 폐루프로.

수치: e2e_fullstage.json · gap_wm.json · gap_e1b.json (CH79 3~4절)

3. 실기 폐루프 결과 (10/28, pos1)

성공 = 수동 기록(episode_log). 구간은 Wilson 95%



63 / 63

A3 (servolabel 1.0) 순수 성공 · 구간 94~100%

· A2(서보 0.5) 14/20, A1(서버 혼합) 11/23

· 서보 라벨이 강할수록 성공이 높음

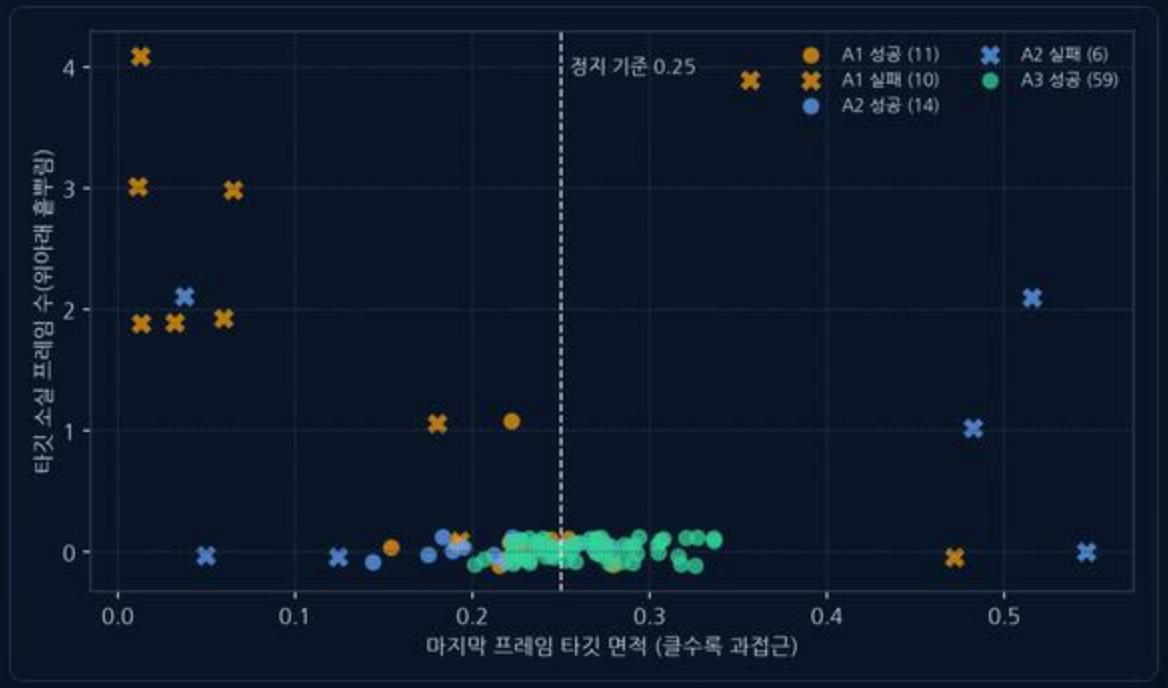
· 타깃 5종 위치 모두 균형(11~13회씩) 성공

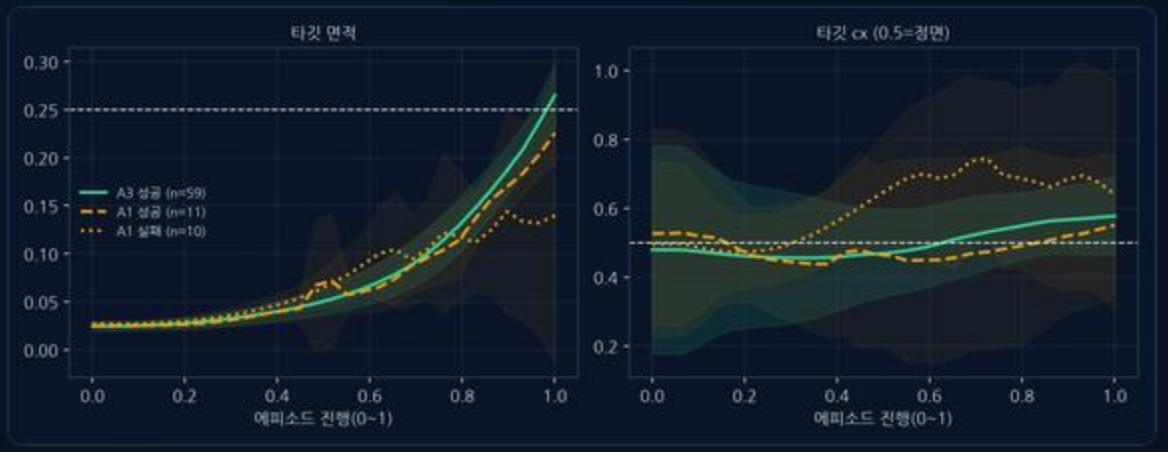
· 단서: ASYNC·EMA 0.0(합의 SYNC/0.5와 다름), 조건별 연속 블록, 기준 A0 1회, pos1만, 수동 판정

집계: ROS_action/dryrun_closedloop_20261028 (JSON 108·H5 102)

4. 판정 편향은 없었나 — 수동 판정과 무관한 H5 확인

영상 bbox만으로 본 마지막 프레임 상태





· A1·A2 **실패**는 타깃 소실이거나 과접근(면적 0.45↑). A3 59개는 전부 면적 0.20~0.34, 소실 0.

· 판정이 후했다면 A3에도 이런 세션이 섞였어야 함 → **편향 증거 없음**. (A3 고유의 다른 실패 유형은 이 방법으로 못 봄)

그림 생성: scripts/ch79_evidence_figs.py

5. 실제 영상 — 성공과 실패의 모습

빨간 상자 = 모델이 잡은 타깃(bbox)

A3 성공 — 바구니에 정면 접근, 면적 0.22~0.32에서 정지



A1 실패 — ① 검은 판을 바구니로 잘못 잡고 벽으로 ② 바구니를 지나쳐 벽만 보임



유형별 2건 예시(시작·중간·마지막 프레임). 전체 통계는 앞 장의 산점도.

6. 평가 코스 — 단계별로 무엇이 가려졌나

오프라인으로 후보를 거르고, 선택은 실기로

단계	측정	알려준 것	한계
① 오프라인 방향 오차	사람 방향과의 차이	A3 +22° → **선택 기준 부적합**	사람 조작=정답 가정
② 반사실 민감도 S	타깃 cx ±0.2 이동 시 행동 변화	서보 라벨↑ → S↑	오프라인 지표
③ 구조 비교	E2E·월드모델 3분할	대체안이 기존 방식을 못 이김	저예산 변형만
④ 실기 페루프	수동 성공 + H5 교차 확인	**A3 63/63**	ASYNC·EMA 0.0, pos1

다음 단계(로봇 측 핸드오프 문서로 전달): A3 pos2·pos3 일반화 → SYNC·EMA 0.5 합의 설정 시험 → 속도 정렬

보고 문구 원칙: "실기 pos1 63/63", 한계 병기. 300회 실기(EGVLA1 92.0%)와 직접 비교하지 않음(조건 다름)

7. 참고한 모델·논문 (1) 구조의 뿌리

그림은 각 논문의 Figure 1(발췌)

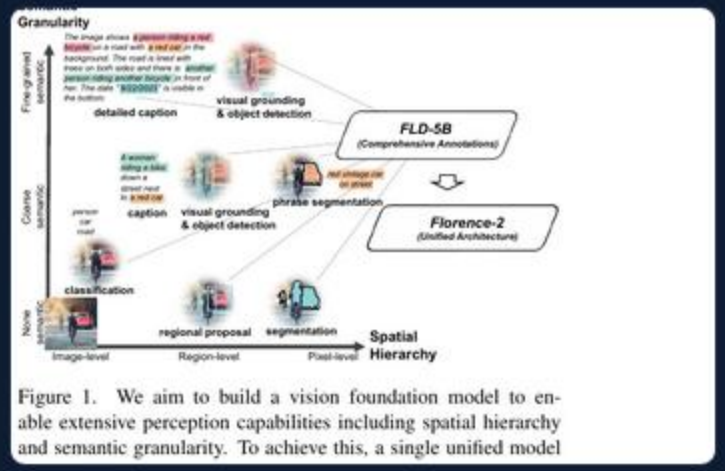


Figure 1. We aim to build a vision foundation model to enable extensive perception capabilities including spatial hierarchy and semantic granularity. To achieve this, a single unified model

Florence-2 (Xiao et al., 2023)

하나의 인코더로 검출·그라운딩 등 통합 — EGVLA2 백본

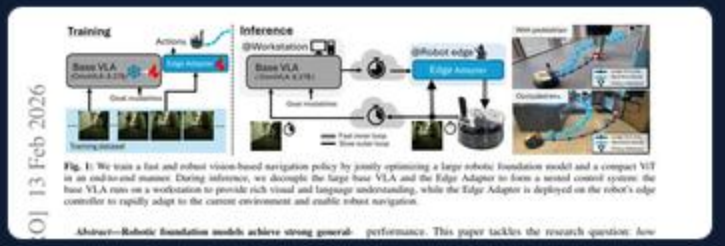
arxiv.org/abs/2311.06224



π0 (Black et al., Physical Intelligence, 2024)

Flow-matching 행동 헤드(AdaLN) — 우리 헤드의 원형

arxiv.org/abs/2410.24164



AsyncVLA (Hirose et al., 2026)

큰 모델 + 엣지 어댑터 비동기 내비게이션 — 경량화 방향 비교

arxiv.org/abs/2602.13476

차용·비교 지점: Florence-2 = 단일 백본 / π0 = 연속 행동을 flow-matching으로 생성 / AsyncVLA = 엣지 실시간성 문제 설정(우리는 단일 소형 백본으로 해결 시도)

7. 참고한 모델·논문 (2) 인식·특징

EGVLA1과 비교·E2E 시험에 사용

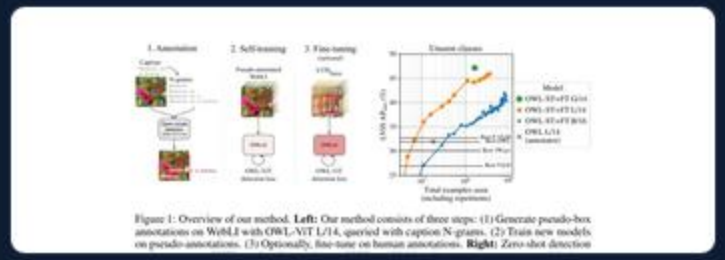


Figure 1: Overview of our method. **Left:** Our method consists of three steps: (1) Generate pseudo-box annotations on WebLI with OWL-ViT L/14, queried with caption N-grams. (2) Train new models on pseudo-annotations. (3) Optionally, fine-tune on human annotations. **Right:** Zero-shot detection

OWLv2 (Minderer et al., 2023)

개방어휘 검출기 — EGVLA1의 타깃 검출

arxiv.org/abs/2306.09683

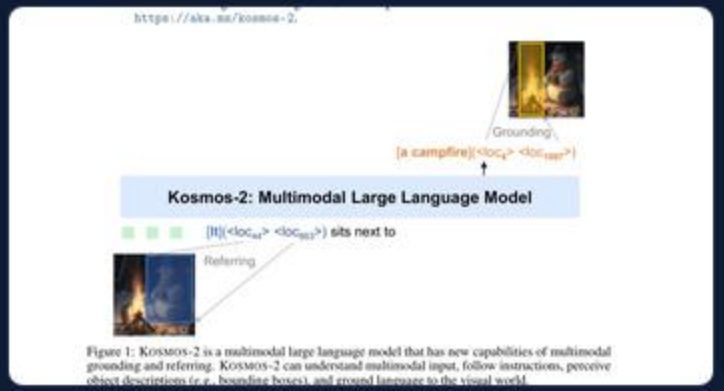


Figure 1: KOSMOS-2 is a multimodal large language model that has new capabilities of multimodal grounding and referring. KOSMOS-2 can understand multimodal input, follow instructions, perceive object descriptions (e.g., bounding boxes), and ground language to the visual world.

Kosmos-2 (Peng et al., 2023)

그라운딩 MLLM — EGVLA1 비전 타워

arxiv.org/abs/2306.14824

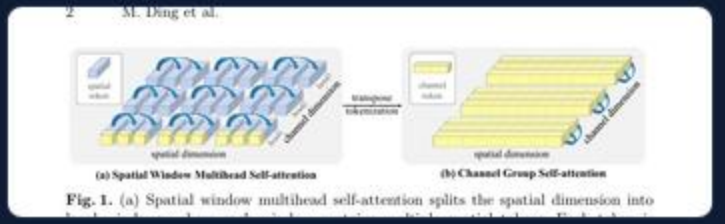


Fig. 1. (a) Spatial window multihead self-attention splits the spatial dimension into

DaViT (Ding et al., 2022)

Florence-2의 비전 인코더 — E2E 시험에서 LoRA 적용

arxiv.org/abs/2204.03645

7. 참고한 모델·논문 (3) 링크 모음

자료	링크	용도
RoboVLMs — What Matters in Building VLA Models	arxiv.org/abs/2412.14058	선행연구 프레임워크(Kosmos-2 백본 학습 레시피)
OpenVLA	arxiv.org/abs/2406.09246	VLA 대표 베이스라인
NaVILA	arxiv.org/abs/2412.04453	내비게이션 VLA 비교(실기 지표 방식)
MobilityVLA	arxiv.org/abs/2407.07775	지시 기반 내비게이션 VLA
TIC-VLA	arxiv.org/abs/2510.03342	지연 보정 내비게이션 VLA
OpenFrontier	arxiv.org/abs/2603.05377	그라운딩 기반 일반 내비게이션
TANGO	arxiv.org/abs/2609.09158	휴머노이드 내비게이션 VLA
π0.7 (월드모델 서브골)	arxiv.org/abs/2604.15483	월드모델식 시도의 동기
V-JEPA 2	arxiv.org/abs/2506.09985	잠재 공간 미래 예측(월드모델식 시도의 참고 방향)
DiT (AdaLN-Zero)	arxiv.org/abs/2212.09748	헤드의 조건 주입 방식
Flow Matching	arxiv.org/abs/2210.02747	행동 생성 학습 원리
LoRA	arxiv.org/abs/2106.09685	E2E 시험의 미세조정 방식
Florence-2-base (HF)	huggingface.co/microsoft/Florence-2-base	사용 체크포인트
OWLv2 ensemble (HF)	huggingface.co/google/owlv2-base-patch16-ensemble	EGVLA1 검출기
Kosmos-2 (HF)	huggingface.co/microsoft/kosmos-2-patch14-224	EGVLA1 비전 타워
레포	github.com/minuum/EdgeGroundVLA	코드·문서(branch inference-integration)

그림 6편 + RoboVLMs·π0.7·V-JEPA 2·DiT·Flow Matching·LoRA는 원문 PDF로 제목 확인. 나머지는 레포 문서의 인용을 그대로 옮김(수치 인용 전 원문 확인 필요)