교수님 보고 2026-10-29

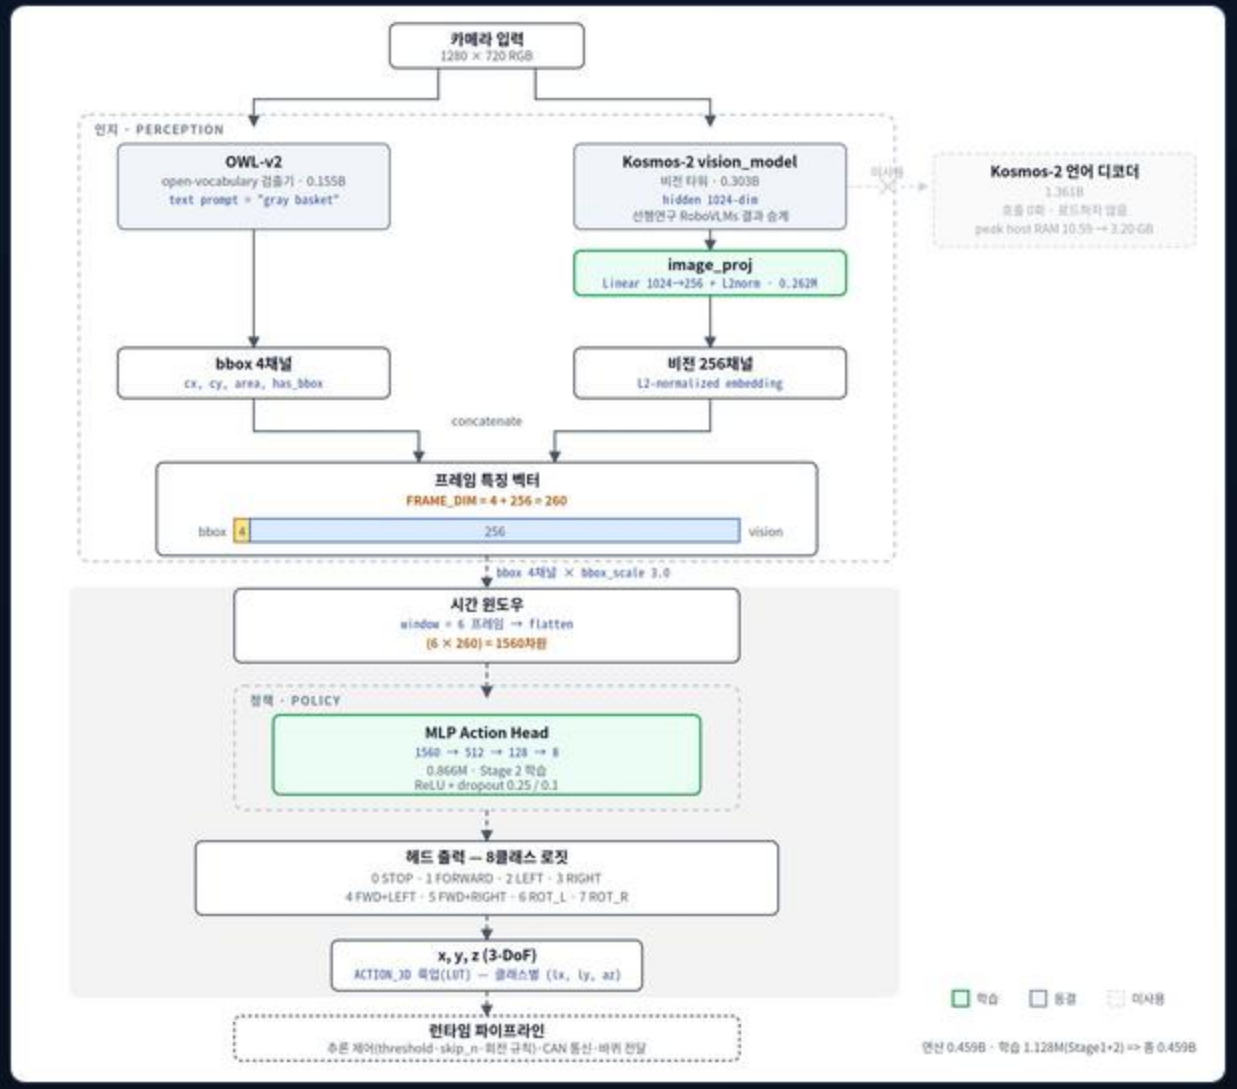
EGVLA2: 단일 백본(Florence-2) 내비게이션 정책 — 실기 폐루프 결과와 현재 모델 확정(A3)

① 무엇을 만들었나 ② 무엇을 시도했나 ③ 실기에서 무엇이 확인됐나 ④ 한계와 다음 단계 ⑤ 참고 문헌

상세: research_story.html#ch79 (📍 현재 상황 탭, 5-2절)

1. 구조 — 두 모델 한눈에

EGVLA1(OWLv2 + Kosmos-2) → EGVLA2(Florence-2 하나로 통합)



EGVLA1: 검출기 + 비전 타워 두 개, MLP 분류 헤드 · 실기 92.0%(276/300)

카메라 이미지

▼

Florence-2 한 번의 인코딩
bbox(cx,cy,area) + 이미지 특징 768-d 동시 추출

▼

bbox 3프레임 창 12-d + 특징 768-d

▼

Flow-matching 행동 헤드 (π0식 AdaLN, H=8)
연속 조이스틱: 방향각 + 속도

▼

서빙: 서보 혼합(선택) → 로봇 명령

· 모델 2개 → **1개**, 헤드는 분류 → **연속 행동**

· 학습: 300 에피소드 · 29,161프레임(pos1)

코드: robovlm_nav/models/egvla2_fm_heads.py · 구조도: docs/v5/figures

2. 시도한 것과 결과 요약

오프라인(같은 분할·라벨·지표) 비교 — 사람 방향 오차(°)는 낮을수록 사람 조작과 같음



E2E(DaViT 미세조정) 변형은 기존 고정 융합 특징(A)을 못 이김. 3분할 평균. 저예산 변형(1 seed, 8 epoch, LoRA 미튜닝)만 시험했으므로 "E2E 무용"이 아니라 "이 변형들은 이득 없음"

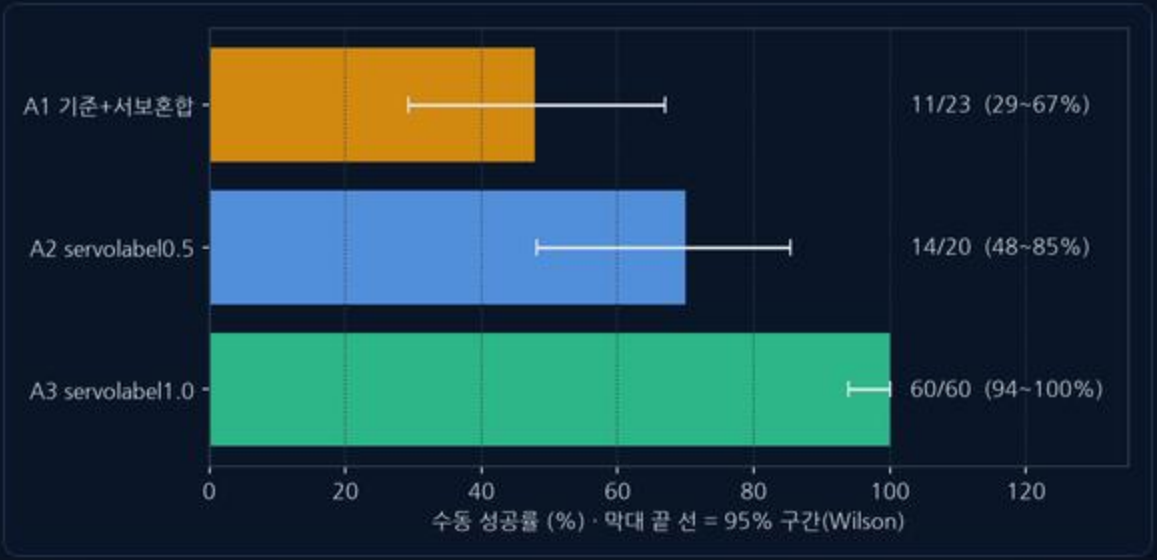
시도	결과
월드모델식 보조 손실 (미래 bbox·특징 변화 예측)	변화 예측은 잘함, **타깃 반응 S는 안 오름** → 1단계에서 중단
서보 라벨(타깃으로 향하는 방향 라벨 혼합)	타깃 반응 S ↑, 오프라인 방향 오차는 ↑(나빠짐)
서버 서보 혼합(A1)	실기 11/23 — 효과 약함

핵심: 오프라인 방향 오차는 모델 선택 기준으로 **부적합**(A3는 +22° 나쁜데 실기는 최고) → 선택은 실기 폐루프로.

수치: e2e_fullstage.json · gap_wm.json · gap_e1b.json (CH79 3~4절)

3. 실기 폐루프 결과 (10/28, pos1)

성공 = 수동 기록(episode_log). 구간은 Wilson 95%



60 / 60

A3 (servolabel 1.0) 시간순 앞 60회 · 구간 94~100%
(같은 날 이어서 한 3회 포함 전체 63/63, 결과 동일)

- A2(서보 0.5) 14/20, A1(서버 혼합) 11/23
- 서보 라벨이 강할수록 성공이 높음
- 타깃 5종 위치 모두 성공(위치별 9~16회)
- 단서: ASYNC·EMA 0.0(합의 SYNC/0.5와 다름), 조건별 연속 블록, 기준 A0 1회, pos1만, 수동 판정

집계: ROS_action/dryrun_closedloop_20261028. 60회 = 순수 A3의 시간순 앞 60회(결과를 본 뒤 정한 구분, 모두 성공이라 결론 불변). A1 23·A2 20은 전체

3-2. 무엇을 "성공"이라 했나 — 판정 근거

성공의 정의는 현장 관찰자의 수동 기록. 영상 bbox로 그 기록을 사후 교차 확인



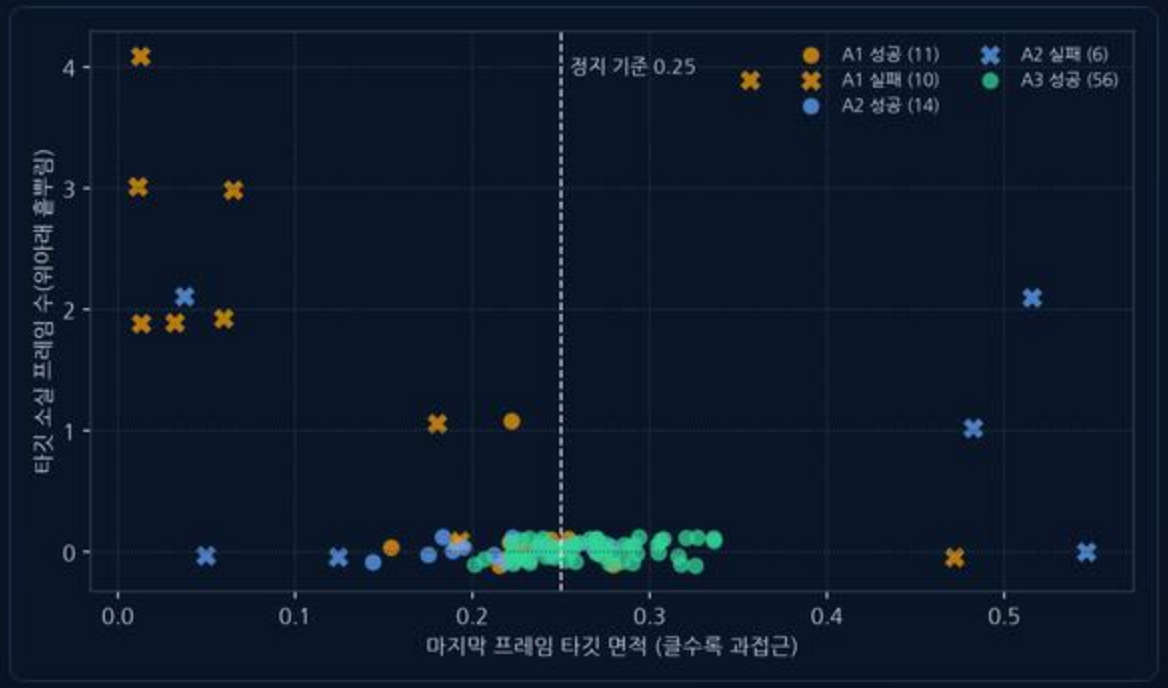
A3 성공 세션: 타깃을 정면에 두고 접근, 마지막 프레임에서 바구니가 화면 하단 중앙을 채우며 정지

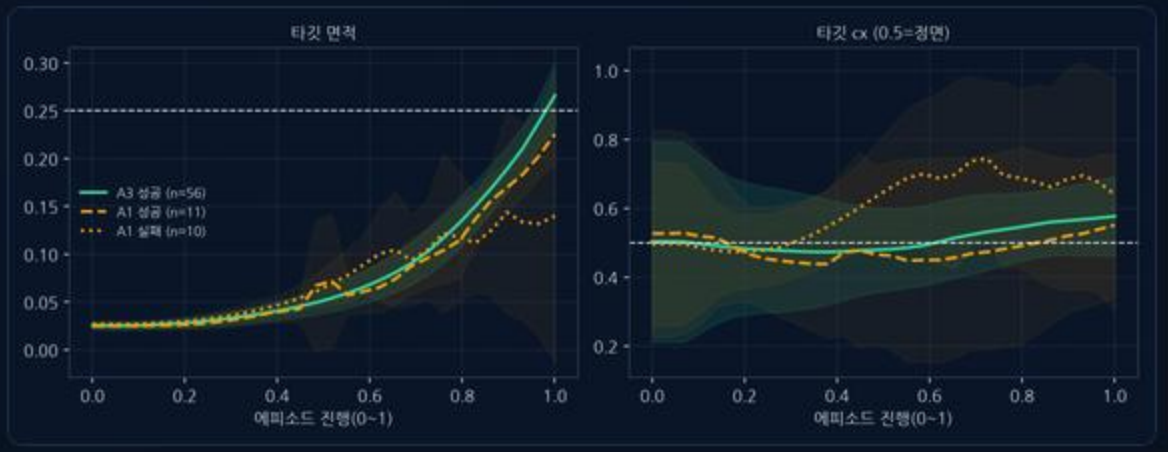
구분	기준
정의(수동)	현장에서 사람이 기록한 결과 열(성공/실패)
성공 세션의 영상 특징	마지막 타깃 면적 0.20~0.34(정지 기준 0.25 근처), 타깃 소실 0프레임, 평균 13.5스텝
실패 세션의 영상 특징	타깃 소실 · 과접근(면적 0.45 이상) · 엉뚱한 물체 추종(A1·A2 실패 16건)

한계: 서면 판정표가 사전에 없었고(핸드오프에는 소실률·정지 거리·성공률 기준만 기재), 조건별 연속 블록이라 판정이 블라인드가 아니었을 가능성이 있다. 그래서 영상 지표로 교차 확인했고, 로봇 측에 실제 사용한 판정 문구와 정지 거리(FPE) 기록을 요청할 예정.

4. 판정 편향은 없었나 — 수동 판정과 무관한 H5 확인

영상 bbox만으로 본 마지막 프레임 상태





· A1·A2 **실패**는 타깃 소실이거나 과접근(면적 0.45↑). A3(H5 보유 56개)는 전부 면적 0.20~0.34, 소실 0.

· 판정이 후했다면 A3에도 이런 세션이 섞였어야 함 → **편향 증거 없음**. (A3 고유의 다른 실패 유형은 이 방법으로 못 봄)

그림 생성: scripts/ch79_evidence_figs.py

5. 실제 영상 — 성공과 실패의 모습

빨간 상자 = 모델이 잡은 타깃(bbox)

A3 성공 — 바구니에 정면 접근, 면적 0.22~0.32에서 정지



A1 실패 — ① 검은 판을 바구니로 잘못 잡고 벽으로 ② 바구니를 지나쳐 벽만 보임



유형별 2건 예시(시작·중간·마지막 프레임). 전체 통계는 앞 장의 산점도.

6. 평가 코스 — 단계별로 무엇이 가려졌나

오프라인으로 후보를 거르고, 선택은 실기로

단계	측정	알려준 것	한계
① 오프라인 방향 오차	사람 방향과의 차이	A3 +22° → **선택 기준 부적합**	사람 조작=정답 가정
② 반사실 민감도 S	타깃 cx ±0.2 이동 시 행동 변화	서보 라벨↑ → S↑	오프라인 지표
③ 구조 비교	E2E·월드모델 3분할	대체안이 기존 방식을 못 이김	저예산 변형만
④ 실기 페루프	수동 성공 + H5 교차 확인	**A3 63/63**	ASYNC·EMA 0.0, pos1

다음 단계(로봇 측 핸드오프 문서로 전달): A3 pos2·pos3 일반화 → SYNC·EMA 0.5 합의 설정 시험 → 속도 정렬

보고 문구 원칙: "실기 pos1 63/63", 한계 병기. 300회 실기(EGVLA1 92.0%)와 직접 비교하지 않음(조건 다름)

핸드오프: docs/plans/HANDOFF_20261029_REPLY_A3_ADOPTED.md

7. 참고한 모델·논문 (1) 구조의 뿌리

그림은 각 논문의 Figure 1(발췌)

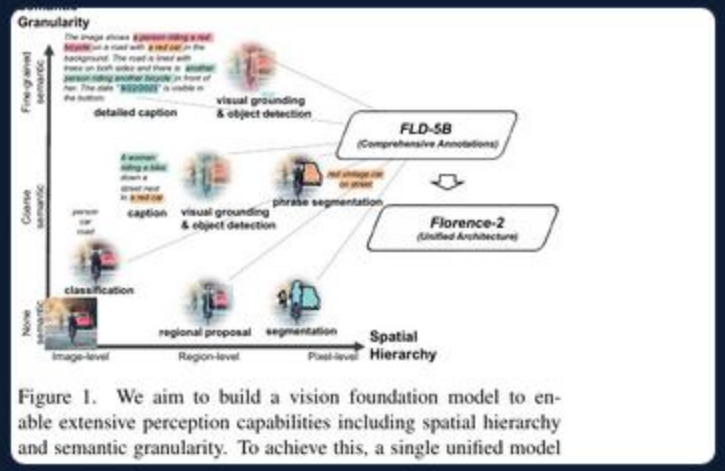


Figure 1. We aim to build a vision foundation model to enable extensive perception capabilities including spatial hierarchy and semantic granularity. To achieve this, a single unified model

Florence-2 (Xiao et al., 2023)

하나의 인코더로 검출·그라운딩 등 통합 — EGVLA2 백본

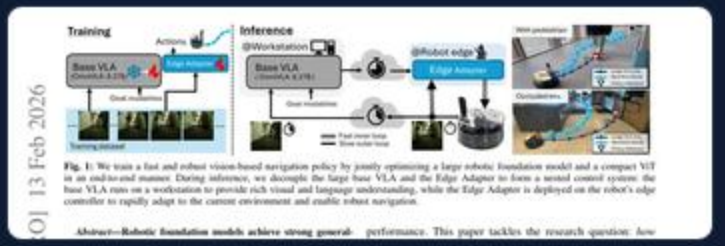
arxiv.org/abs/2311.06224



π0 (Black et al., Physical Intelligence, 2024)

Flow-matching 행동 헤드(AdaLN) — 우리 헤드의 원형

arxiv.org/abs/2410.24164



AsyncVLA (Hirose et al., 2026)

큰 모델 + 엣지 어댑터 비동기 내비게이션 — 경량화 방향 비교

arxiv.org/abs/2602.13476

차용·비교 지점: Florence-2 = 단일 백본 / π0 = 연속 행동을 flow-matching으로 생성 / AsyncVLA = 엣지 실시간성 문제 설정(우리는 단일 소형 백본으로 해결 시도)

7. 참고한 모델·논문 (2) 인식·특징

EGVLA1과 비교·E2E 시험에 사용

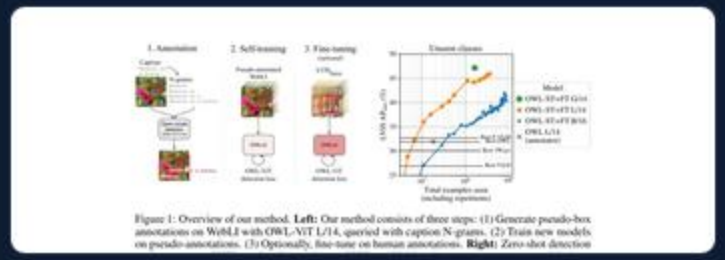


Figure 1: Overview of our method. **Left:** Our method consists of three steps: (1) Generate pseudo-box annotations on WebLI with OWL-ViT L/14, queried with caption N-grams. (2) Train new models on pseudo-annotations. (3) Optionally, fine-tune on human annotations. **Right:** Zero-shot detection

OWLv2 (Minderer et al., 2023)

개방어휘 검출기 — EGVLA1의 타깃 검출

arxiv.org/abs/2306.09683

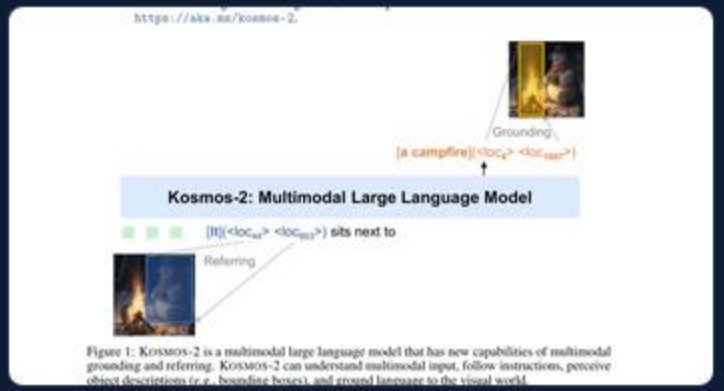


Figure 1: KOSMOS-2 is a multimodal large language model that has new capabilities of multimodal grounding and referring. KOSMOS-2 can understand multimodal input, follow instructions, perceive object descriptions (e.g., bounding boxes), and ground language to the visual world.

Kosmos-2 (Peng et al., 2023)

그라운딩 MLLM — EGVLA1 비전 타워

arxiv.org/abs/2306.14824

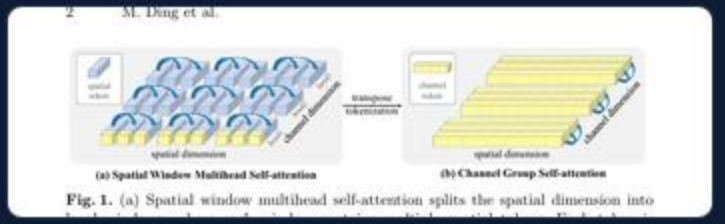


Fig. 1. (a) Spatial window multihead self-attention splits the spatial dimension into

DaViT (Ding et al., 2022)

Florence-2의 비전 인코더 — E2E 시험에서 LoRA 적용

arxiv.org/abs/2204.03645

7. 참고한 모델·논문 (3) 링크 모음

자료	링크	용도
RoboVLMs — What Matters in Building VLA Models	arxiv.org/abs/2412.14058	선행연구 프레임워크(Kosmos-2 백본 학습 레시피)
OpenVLA	arxiv.org/abs/2406.09246	VLA 대표 베이스라인
NaVILA	arxiv.org/abs/2412.04453	내비게이션 VLA 비교(실기 지표 방식)
MobilityVLA	arxiv.org/abs/2407.07775	지시 기반 내비게이션 VLA
TIC-VLA	arxiv.org/abs/2510.03342	지연 보정 내비게이션 VLA
OpenFrontier	arxiv.org/abs/2603.05377	그라운딩 기반 일반 내비게이션
TANGO	arxiv.org/abs/2609.09158	휴머노이드 내비게이션 VLA
π0.7 (월드모델 서브골)	arxiv.org/abs/2604.15483	월드모델식 시도의 동기
V-JEPA 2	arxiv.org/abs/2506.09985	잠재 공간 미래 예측(월드모델식 시도의 참고 방향)
DiT (AdaLN-Zero)	arxiv.org/abs/2212.09748	헤드의 조건 주입 방식
Flow Matching	arxiv.org/abs/2210.02747	행동 생성 학습 원리
LoRA	arxiv.org/abs/2106.09685	E2E 시험의 미세조정 방식
Florence-2-base (HF)	huggingface.co/microsoft/Florence-2-base	사용 체크포인트
OWLv2 ensemble (HF)	huggingface.co/google/owlv2-base-patch16-ensemble	EGVLA1 검출기
Kosmos-2 (HF)	huggingface.co/microsoft/kosmos-2-patch14-224	EGVLA1 비전 타워
레포	github.com/minuum/EdgeGroundVLA	코드·문서(branch inference-integration)

그림 6편 + RoboVLMs·π0.7·V-JEPA 2·DiT·Flow Matching·LoRA는 원문 PDF로 제목 확인. 나머지는 레포 문서의 인용을 그대로 옮김(수치 인용 전 원문 확인 필요)